

Procesamiento de textos (parte II)

Julian D. Echeverry-Correa

jde@utp.edu.co

Técnicas de Procesamiento de Lenguaje Natural

Doctorado en Ingeniería

Maestría en Ingeniería Eléctrica

Maestría en Ingeniería de Sistemas

Maestría en Investigación Operativa y Estadística

Grupo de Investigación en Análisis de Datos y Sociología Computacional - GIADSc

Universidad Tecnológica de Pereira - 2025



Contenido

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words
- 4 Etiquetado gramatical
- 5 Reconocimiento de entidades nombradas
- 6 Word collocations - Colocaciones de palabras

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words
- 4 Etiquetado gramatical
- 5 Reconocimiento de entidades nombradas
- 6 Word collocations - Colocaciones de palabras

Veremos en esta clase:

- Algunos aspectos complementarios del preprocesamiento de textos.
- Etapas para la identificación de partes del habla.
- Análisis sintáctico.
- Reconocimiento de entidades nombradas (NER - *Named Entity Recognition*).
- Identificación de colocaciones.

Contenido

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words
- 4 Etiquetado gramatical
- 5 Reconocimiento de entidades nombradas
- 6 Word collocations - Colocaciones de palabras

Sobre el preprocesamiento de textos

Recordemos que los objetivos de preprocesar los textos de entrada son:

- Verificar (y en muchos casos corregir) la codificación de los textos.
 - Por ejemplo, convertir de UTF-8 a ANSI, de UCS-2 a UTF-8, etc.
 - Revisar los finales de línea (caracteres EOL - formatos Windows, UNIX, MAC).
 - Verificar los juegos de caracteres (ver ejemplo en Notepad++).
- Reducir el tamaño del vocabulario con el que vamos a trabajar.
- Eliminar caracteres no deseados.
- Y de manera general, podemos decir que el preprocesamiento es necesario para que los *modelos de aprendizaje de máquina* y de *reconocimiento de patrones* tengan un mejor desempeño.

Sobre el preprocesamiento de textos

- No todos los signos de puntuación deben ser eliminados.

Ejemplos:

Sentencia de la Corte 15.23.2019

COMMAND.COM SYSTEM32.BIN

El sistema operativo OS/2

El canal de televisión E! Entertainment Television

- Tenemos que ser cuidadosos a la hora de procesar números.

Ejemplos:

Analizar los compuestos derivados de la vitamina B-12

El COVID-19 tendrá nuevas variantes como la 501Y.V2

Sobre el procesamiento de textos

- Trabajando con publicaciones de redes sociales es importante tokenizar adecuadamente los hashtags (#) y las menciones (@).

Ejemplos:

@MinEducacion sigue dando problemas con las convalidaciones #MasRespeto

Código de ejemplo:

```
In [52]: from nltk.tokenize import TweetTokenizer

tweets = ['Este es un ejemplo de como #tokenizar en #python',
          'Este curso de #PLN es el mejor del mundo mundial!',
          'Esto es posible en @UTPereira :) #PLN #python']

# Lo podemos hacer empleando expresiones regulares
patron = r"([@#]\w+)"
# Usamos el patrón para buscar hashtags o menciones
mentions_hashtags = regexp_tokenize(tweets[-1], patron)
print(mentions_hashtags)

# Usamos el TweetTokenizer para tokenizar todos los tweets y llevarlos a una lista
tknznr = TweetTokenizer()
all_tokens = [tknznr.tokenize(t) for t in tweets]
print(all_tokens)

['@UTPereira', '#PLN', '#python']
[['Este', 'es', 'un', 'ejemplo', 'de', 'como', '#tokenizar', 'en', '#python'], ['Este', 'curso', 'de', '#PLN', 'es', 'el', 'mejor', 'del', 'mundo', 'mundial', '!'], ['Esto', 'es', 'posible', 'en', '@UTPereira', ':)', '#PLN', '#python']]
```


Sobre el preprocesamiento de textos

- Los **emoticonos** (emojis) deben procesarse adecuadamente, sobre todo en tareas de *Sentiment Analysis*¹²

Ejemplos:



Así me siento hoy sobre el proceso de paz 🙄



Así me siento hoy sobre el proceso de paz 😊

¹<https://hal-amu.archives-ouvertes.fr/hal-01529708/document>

²<https://unicode.org/emoji/charts/full-emoji-list.html>

Sobre el preprocesamiento de textos

- Ejemplo de código de tokenización de emojis:

```
In [49]: spanish_text = '¿Quién quiere ir a comer 🍷 conmigo y a dar una vuelta en 🚗 ?'
# Tokenizar e imprimir todas las palabras
all_words_esp = word_tokenize(spanish_text)
print(all_words_esp)

# Tokenizar e imprimir solo los emojis
emoji = "['\U0001F300-\U0001F5FF' | '\U0001F600-\U0001F64F' | '\U0001F680-\U0001F6FF' | '\u2600-\u26FF\u2700-\u27BF']"
print(regex_tokenizer(spanish_text, emoji))

['¿Quién', 'quiere', 'ir', 'a', 'comer', '🍷', 'conmigo', 'y', 'a', 'dar', 'una', 'vuelta', 'en', '🚗', '?']
[🍷, 🚗]
```

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words**
- 4 Etiquetado gramatical
- 5 Reconocimiento de entidades nombradas
- 6 Word collocations - Colocaciones de palabras

Eliminación de *stop-words*

- Se conoce como *stop-words* a todas aquellas palabras que no aportan información a la tarea de PLN que se esté realizando.
- Por lo general son aquellas palabras muy comunes (artículos, preposiciones, algunos verbos como ser o estar, adverbios, etc.).
- La eliminación de las *stop-words* nos puede ahorrar mucho tiempo de cómputo y puede contribuir a la tarea de reducir el tamaño del vocabulario.
- Ya existen listas predefinidas de *stop-words*; sin embargo conviene revisar estas listas predefinidas previamente o crear una lista propia para cada tarea que se vaya a realizar.

Tareas adicionales de preprocesamiento

- El preprocesamiento de los textos no consiste solo en tokenizar y generar un listado de los términos presentes en los textos.
- Comprende también el **etiquetado gramatical**, la **identificación de entidades** y el **análisis sintáctico** de las frases.
- Estas tareas no son necesarias en todas las aplicaciones del PLN, pero podrían enriquecer la calidad de los vocabularios y aportar más información al análisis de textos y al entrenamiento de modelos de aprendizaje.
- Son imprescindibles en tareas de comprensión de lenguaje natural (NLU - *Natural Language Understanding*).

Contenido

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words
- 4 Etiquetado gramatical**
- 5 Reconocimiento de entidades nombradas
- 6 Word collocations - Colocaciones de palabras

- También conocido como etiquetado morfológico o *POS-tagging* (*Part-Of-Speech*).
- Es el proceso de asignar una etiqueta a una palabra dada dentro de una frase de acuerdo con el papel que juega dicha palabra como parte del habla (o del discurso).
- Ejemplos de etiquetas o categorías gramaticales son: sustantivo, verbo, adjetivo, etc.

- En inglés, las etiquetadas más empleadas son las del *Penn Treebank tagset* ³
- En español, las etiquetas son distintas. La morfología del español es más rica (y por tanto, más difícil de analizar), p.ej. los adjetivos tienen género y número, con lo que ya no basta la etiqueta JJ del inglés para los adjetivos ⁴.
- Las etiquetas aportan gran cantidad de información sobre una palabra y sus vecinos. Nos permite identificar entidades y son fundamentales en tareas de recuperación de información.


³<https://www.sketchengine.eu/penn-treebank-tagset/>

⁴<https://www.sketchengine.eu/spanish-freeling-part-of-speech-tagset/>

Etiquetado gramatical

¿Dónde radica su dificultad?

- En el hecho de que una palabra puede pertenecer a dos o más etiquetas.



Los etiquetadores POS son entrenados a partir de corpus lingüísticos.

- Corpus de Brown → primer corpus en inglés (aprox. 1 millón de palabras).
- Corpus del Wall Street Journal (aprox. 1 millón de palabras).
- Wikicorpus (aprox. 120 millones de palabras).
- En español, de los más completos es el corpus AnCora⁵ usado, entre otros, por UDPipe (<http://lindat.mff.cuni.cz/services/udpipe/>)⁶.

⁵http://www.lrec-conf.org/proceedings/lrec2008/pdf/35_paper.pdf

⁶<https://ufal.mff.cuni.cz/udpipe>

Etiquetado gramatical

Veamos ejemplos del etiquetado POS:

<http://lindat.mff.cuni.cz/services/udpipe/>

```
In [23]: snlp = stanza.Pipeline(lang="es")
         nlp = StanzaLanguage(snlp)

         doc = nlp("Los diálogos de paz de Santos con la guerrilla de las FARC finalizaron con el acuerdo que se firmó en Colombia en 2016")
         for token in doc:
             print(token.text, token.lemma_, token.pos_, token.dep_, token.ent_type_)
         print(doc.ents)
```

```
Los el DET det
diálogos diálogo NOUN nsubj
de de ADP case
paz paz NOUN nmod
de de ADP case
Santos Santos PROPN nmod PER
con con ADP case
la el DET det
guerrilla guerrilla NOUN nmod
de de ADP case
las el DET det
FARC FARC PROPN nmod ORG
finalizaron finalizar VERB root
con con ADP case
el el DET det
acuerdo acuerdo NOUN obl
que que PRON nsubj
se él PRON obj
firmó firmar VERB acl
en en ADP case
Colombia Colombia PROPN obl LOC
en en ADP case
2016 2016 NOUN obl
. . PUNCT punct
(Santos, FARC, Colombia)
```

Etiquetado gramatical

Veamos ejemplos del etiquetado POS:

```
In [35]: snlp = stanza.Pipeline(lang="en")
         nlp = StanzaLanguage(snlp)

         doc = nlp("Barack Obama was born in Hawaii. He was elected president in 2008.")
         for token in doc:
             print(token.text, token.lemma_, token.pos_, token.dep_, token.ent_type_)
         print(doc.ents)

         from spacy import displacy

         nlp = spacy.load("en_core_web_sm")
         #doc = nlp("This is a sentence.")
         displacy.render(doc, style="dep")
```

```
Barack Barack PROPN nsubj:pass PERSON
Obama Obama PROPN flat PERSON
was be AUX aux:pass
born bear VERB root
in in ADP case
Hawaii Hawaii PROPN obl GPE
. . PUNCT punct
He he PRON nsubj:pass
was be AUX aux:pass
elected elect VERB root
president president PROPN xcomp
in in ADP case
2008 2008 NUM obl DATE
. . PUNCT punct
(Barack Obama, Hawaii, 2008)
```

Aplicaciones del etiquetado POS

- En el desarrollo de sistemas de traducción automática.
- Para la predicción de palabras en sistemas de reconocimiento automático de habla.
- En sistemas de corrección gramatical.

Contenido

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words
- 4 Etiquetado gramatical
- 5 Reconocimiento de entidades nombradas**
- 6 Word collocations - Colocaciones de palabras

- El **Reconocimiento de Entidades Nombradas** (*NER - Named Entity Recognition*) o simplemente reconocimiento de entidades, es el proceso por medio del cual se detectan y se extraen entidades comunes dentro de un texto.
- Se encuentra en la literatura como *entity identification*, *entity chunking* o *entity extraction*.
- Entendemos **entidades comunes** como personas, lugares, instituciones, fechas, nombres propios, etc.
- Ya existen modelos pre-entrenados para el reconocimiento de entidades, sin embargo, se pueden entrenar modelos nuevos a partir de textos propios para mejorar el reconocimiento de nuevas entidades.

Reconocimiento de entidades nombradas


Veamos un ejemplo:

```
In [42]: text = "Los diálogos de paz de Santos con la guerrilla de las FARC finalizaron con el acuerdo que se firmó en Colombia en 2016."  
nlp = spacy.load("es_core_news_sm")  
doc = nlp(text)  
displacy.render(doc, style="ent")
```

Los diálogos de paz de Santos **MISC** con la guerrilla de las **FARC ORG** finalizaron con el acuerdo que se firmó en **Colombia LOC** en 2016.

Análisis sintáctico

- El análisis sintáctico busca dar sentido a las frases mediante el etiquetado de las palabras en una frase de acuerdo a las reglas de la gramática.



Contenido

- 1 Introducción
- 2 Preprocesamiento de textos
- 3 Eliminación de stop-words
- 4 Etiquetado gramatical
- 5 Reconocimiento de entidades nombradas
- 6 Word collocations - Colocaciones de palabras**

- A un hablante de español, la siguiente frase podrá parecerle extraña

A Juan le introdujeron ganas de salir, pero albergó una decepción al ver que llovía.

- En español, la construcción **introducir ganas** no es común. Está bien escrita (gramaticalmente hablando) pero su uso no es frecuente. Lo mismo ocurre con **albergó una decepción**.
- Lo común sería emplear **le dieron ganas de salir** y **se llevó una decepción**. Estas combinaciones de **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre** (y algunas otras más) es lo que llamamos colocaciones del español.

- A un hablante de español, la siguiente frase podrá parecerle extraña
A Juan le introdujeron ganas de salir, pero albergó una decepción al ver que llovía.
- En español, la construcción **introducir ganas** no es común. Está bien escrita (gramaticalmente hablando) pero su uso no es frecuente. Lo mismo ocurre con **albergó una decepción**.
- Lo común sería emplear **le dieron ganas de salir** y **se llevó una decepción**. Estas combinaciones de **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre** (y algunas otras más) es lo que llamamos colocaciones del español.

- A un hablante de español, la siguiente frase podrá parecerle extraña

A Juan le introdujeron ganas de salir, pero albergó una decepción al ver que llovía.

- En español, la construcción **introducir ganas** no es común. Está bien escrita (gramaticalmente hablando) pero su uso no es frecuente. Lo mismo ocurre con **albergó una decepción**.
- Lo común sería emplear **le dieron ganas de salir** y **se llevó una decepción**. Estas combinaciones de **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre** (y algunas otras más) es lo que llamamos colocaciones del español.

- Las **colocaciones** se trata de combinaciones que a cualquier hablante nativo le resultan conocidas, pero que no son en modo alguno evidentes.
- Ejemplos:

vino tinto, fracasar estrepitosamente, cancelar semestre.

- Las **colocaciones** son imprevisibles, de ahí que sea necesario estudiarlas. En español decimos *dar una vuelta*, mientras en italiano se dice *fare una passeggiata* y en francés *faire une promenade*; en estos otros idiomas emplean el verbo hacer, en vez del verbo dar.
- Lo curioso de esto es que incluso en expresiones con rasgos comunes en su significado, se combinan a veces con otros verbos: no decimos *dar una excursión*, decimos *hacer una excursión*, no decimos *dar un recorrido*, decimos *hacer un recorrido*.

- Las **colocaciones** se trata de combinaciones que a cualquier hablante nativo le resultan conocidas, pero que no son en modo alguno evidentes.
- Ejemplos:

vino tinto, fracasar estrepitosamente, cancelar semestre.

- Las **colocaciones** son imprevisibles, de ahí que sea necesario estudiarlas. En español decimos *dar una vuelta*, mientras en italiano se dice *fare una passeggiata* y en francés *faire une promenade*; en estos otros idiomas emplean el verbo hacer, en vez del verbo dar.
- Lo curioso de esto es que incluso en expresiones con rasgos comunes en su significado, se combinan a veces con otros verbos: no decimos *dar una excursión*, decimos *hacer una excursión*, no decimos *dar un recorrido*, decimos *hacer un recorrido*.

- Las **colocaciones** se trata de combinaciones que a cualquier hablante nativo le resultan conocidas, pero que no son en modo alguno evidentes.
- Ejemplos:

vino tinto, fracasar estrepitosamente, cancelar semestre.

- Las **colocaciones** son imprevisibles, de ahí que sea necesario estudiarlas. En español decimos *dar una vuelta*, mientras en italiano se dice *fare una passeggiata* y en francés *faire une promenade*; en estos otros idiomas emplean el verbo hacer, en vez del verbo dar.
- Lo curioso de esto es que incluso en expresiones con rasgos comunes en su significado, se combinan a veces con otros verbos: no decimos *dar una excursión*, decimos *hacer una excursión*, no decimos *dar un recorrido*, decimos *hacer un recorrido*.

- ¿Por qué es importante el estudio de las colocaciones?

- Porque nos permite entender mejor el sentido de una expresión.

hacer una vuelta vs. dar una vuelta

- Porque son necesarias en tareas de traducción.

real estate = bienes raíces
real estate ≠ inmuebles reales

- Porque nos permiten caracterizar el contexto (temática, autor, dominio, etc.)

yes we can
gloria inmarcesible

- ¿Por qué es importante el estudio de las colocaciones?

- Porque nos permite entender mejor el sentido de una expresión.

hacer una vuelta vs. dar una vuelta

- Porque son necesarias en tareas de traducción.

real estate = bienes raíces

real estate ≠ inmuebles reales

- Porque nos permiten caracterizar el contexto (temática, autor, dominio, etc.)

yes we can

gloria inmarcesible

- ¿Por qué es importante el estudio de las colocaciones?

- Porque nos permite entender mejor el sentido de una expresión.

hacer una vuelta vs. dar una vuelta

- Porque son necesarias en tareas de traducción.

real estate = bienes raíces

real estate ≠ inmuebles reales

- Porque nos permiten caracterizar el contexto (temática, autor, dominio, etc.)

yes we can

gloria inmarcesible

- ¿Por qué es importante el estudio de las colocaciones?
 - Porque nos permite entender mejor el sentido de una expresión.
hacer una vuelta vs. dar una vuelta
 - Porque son necesarias en tareas de traducción.
real estate = bienes raíces
real estate ≠ inmuebles reales
 - Porque nos permiten caracterizar el contexto (temática, autor, dominio, etc.)
yes we can
gloria inmarcesible

Análisis de colocaciones

- La forma más sencilla de encontrar colocaciones en un texto es mediante el conteo de repeticiones.
- Si dos palabras ocurren juntas un determinado número de veces, es evidente que ellas tienen alguna función distinta (en comparación simplemente a su ubicación conjunta en el texto).

Sin embargo, seleccionar las combinaciones de palabras (en este caso **bigramas**) más comunes no resulta una forma óptima de abordar esta tarea.

Análisis de colocaciones

- La forma más sencilla de encontrar colocaciones en un texto es mediante el conteo de repeticiones.
- Si dos palabras ocurren juntas un determinado número de veces, es evidente que ellas tienen alguna función distinta (en comparación simplemente a su ubicación conjunta en el texto).

$C(w^1 w^2)$	w^1	w^2
80871	of	the
58841	in	the
26430	to	the
21842	on	the
21839	for	the
18568	and	the
16121	that	the
15630	at	the
15494	to	be
13899	in	a
13689	of	a
13361	by	the
13183	with	the
12622	from	the
11428	New	York
10007	he	said
9775	as	a
9231	is	a
8753	has	been
8573	for	a

Sin embargo, seleccionar las combinaciones de palabras (en este caso **bigramas**) más comunes no resulta una forma óptima de abordar esta tarea.

- Otra forma de encontrar colocaciones es buscando parejas (o grupos) de palabras que cumplan con patrones sintácticos.
 - Habíamos dicho antes que las colocaciones eran **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre**, entre otras.
- Pues bien, buscando conjuntos de palabras que cumplan estos requisitos se pueden encontrar colocaciones.
- Este “etiquetado” sintáctico se puede realizar mediante **POS-taggers** (*Part-Of-Speech taggers*).

- Otra forma de encontrar colocaciones es buscando parejas (o grupos) de palabras que cumplan con patrones sintácticos.
 - Habíamos dicho antes que las colocaciones eran **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre**, entre otras.
- Pues bien, buscando conjuntos de palabras que cumplan estos requisitos se pueden encontrar colocaciones.
- Este “etiquetado” sintáctico se puede realizar mediante **POS-taggers** (*Part-Of-Speech taggers*).

- Otra forma de encontrar colocaciones es buscando parejas (o grupos) de palabras que cumplan con patrones sintácticos.
 - Habíamos dicho antes que las colocaciones eran **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre**, entre otras.
- Pues bien, buscando conjuntos de palabras que cumplan estos requisitos se pueden encontrar colocaciones.
- Este “etiquetado” sintáctico se puede realizar mediante **POS-taggers** (*Part-Of-Speech taggers*).

- Otra forma de encontrar colocaciones es buscando parejas (o grupos) de palabras que cumplan con patrones sintácticos.
 - Habíamos dicho antes que las colocaciones eran **verbo y nombre**, **nombre y adjetivo** o **nombre y nombre**, entre otras.
- Pues bien, buscando conjuntos de palabras que cumplan estos requisitos se pueden encontrar colocaciones.
- Este “etiquetado” sintáctico se puede realizar mediante **POS-taggers** (*Part-Of-Speech taggers*).

Análisis de colocaciones

Tag Pattern	Example
A N	<i>linear function</i>
N N	<i>regression coefficients</i>
A A N	<i>Gaussian random variable</i>
A N N	<i>cumulative distribution function</i>
N A N	<i>mean squared error</i>
N N N	<i>class probability function</i>
N P N	<i>degrees of freedom</i>

$C(w^1 w^2)$	w^1	w^2	Tag Pattern
11487	New	York	A N
7261	United	States	A N
5412	Los	Angeles	N N
3301	last	year	A N
3191	Saudi	Arabia	N N
2699	last	week	A N
2514	vice	president	A N
2378	Persian	Gulf	A N
2161	San	Francisco	N N
2106	President	Bush	N N
2001	Middle	East	A N
1942	Saddam	Hussein	N N
1867	Soviet	Union	A N
1850	White	House	A N
1633	United	Nations	A N
1337	York	City	N N
1328	oil	prices	N N
1210	next	year	A N
1074	chief	executive	A N
1073	real	estate	A N

Media y varianza

- Muchas colocaciones permiten una relación más flexible entre ellas. Pensemos, por ejemplo, en las palabras **tocar** y **puerta** y en las siguientes construcciones:
 - Ellos **tocaron** la **puerta**
 - Se le pidió que **tocara** de forma contundente la **puerta**
 - No **toques** la **puerta**
 - Por mucho que **toqué**, nadie abrió la **puerta**
- Vemos que las palabras que aparecen entre **tocar** y **puerta** varían, y la *distancia* entre ellas no permanece constante. Entiéndase por *distancia* el número de palabras entre ellas.
- Por estas razones, los enfoques anteriores pueden no ofrecer buenos resultados.

Media y varianza

- Muchas colocaciones permiten una relación más flexible entre ellas. Pensemos, por ejemplo, en las palabras **tocar** y **puerta** y en las siguientes construcciones:
 - Ellos **tocaron** la **puerta**
 - Se le pidió que **tocara** de forma contundente la **puerta**
 - No **toques** la **puerta**
 - Por mucho que **toqué**, nadie abrió la **puerta**
- Vemos que las palabras que aparecen entre **tocar** y **puerta** varían, y la *distancia* entre ellas no permanece constante. Entiéndase por *distancia* el número de palabras entre ellas.
- Por estas razones, los enfoques anteriores pueden no ofrecer buenos resultados.

Media y varianza

- Muchas colocaciones permiten una relación más flexible entre ellas. Pensemos, por ejemplo, en las palabras **tocar** y **puerta** y en las siguientes construcciones:
 - Ellos **tocaron** la **puerta**
 - Se le pidió que **tocara** de forma contundente la **puerta**
 - No **toques** la **puerta**
 - Por mucho que **toqué**, nadie abrió la **puerta**
- Vemos que las palabras que aparecen entre **tocar** y **puerta** varían, y la *distancia* entre ellas no permanece constante. Entiéndase por *distancia* el número de palabras entre ellas.
- Por estas razones, los enfoques anteriores pueden no ofrecer buenos resultados.

- **Media y varianza**

- Un método efectivo para descubrir las relaciones entre palabras es medir la **media** y **varianza** de la distancia entre ellas.
- De los ejemplos anteriores, la **media** de la distancia entre **tocar** y **puerta** sería

$$\frac{1}{4}(2 + 5 + 2 + 5) = 3.5$$

- Tenemos que restringir el análisis a una ventana de m palabras.
- Y la **varianza** como


$$s^2 = \frac{\sum_{i=1}^n (d_i - \bar{d})^2}{n - 1}$$

Donde n es el número de veces que las palabras co-ocurren (teniendo en cuenta una ventana de m palabras). Para el ejemplo

$$s = \sqrt{\frac{1}{3} ((2 - 3.5)^2 + (5 - 3.5)^2 + (2 - 3.5)^2 + (5 - 3.5)^2)} \approx 1.732$$

- La **media** y **varianza** caracteriza la distribución de las distancias entre dos palabras en un corpus.
- Podemos entonces descubrir colocaciones buscando pares de palabras con una baja desviación.
- Una baja desviación indicaría que las palabras suelen ocurrir normalmente a la misma distancia.

Análisis de colocaciones



Información mutua

- Mide la cantidad de información que una palabra aporta acerca de otra.
- Definida como

$$I(x, y) = \log_2 \frac{p(x, y)}{p(x)p(y)}$$

Información mutua

- Mide la cantidad de información que una palabra aporta acerca de otra.
- Definida como

$$I(x, y) = \log_2 \frac{p(x, y)}{p(x)p(y)}$$

- **Información mutua**

- Veamos un ejemplo

$C(w^1)$	$C(w^2)$	$C(w^1 w^2)$	w^1	w^2
42	20	20	Ayatollah	Ruhollah
41	27	20	Bette	Midler
30	117	20	Agatha	Christie
77	59	20	videocassette	recorder
24	320	20	unsalted	butter
14907	9017	20	first	made
13484	10570	20	over	many
14734	13478	20	into	them
14093	14776	20	like	people
15019	15629	20	time	last

- El corpus tiene un total de 14307668 tokens.

Referencias I



Manning, C. and Schütze, H. (2001).
Foundations of Statistical Natural Language Processing.
The MIT Press. 1st Edition. 2001



Jurafsky, D. and Martin, J. (2008).
Speech and Language Processing
Ed. Pearson. 2008