

Clasificación de textos - parte 1

Julian D. Echeverry-Correa
jde@utp.edu.co

Técnicas de Procesamiento de Lenguaje Natural

Doctorado en Ingeniería - Maestría en Ingeniería Eléctrica

Maestría en Ingeniería de Sistemas - Maestría en Investigación Operativa y Estadística

Grupo de Investigación en Análisis de Datos y Sociología Computacional - GIADSc
Universidad Tecnológica de Pereira - 2025



- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

- Hemos visto algunas tareas dentro del PLN que podríamos considerar tareas de clasificación de textos:
 - *Parser* gramaticales.
 - Lematización.
 - Generación de *n-gramas*.
 - ... entre otros.
- La tarea de clasificación de textos consiste específicamente en asignar un texto a una clase (en este caso las clases son temáticas definidas dentro del corpus).
- Es una tarea que de forma natural los humanos hacemos bastante bien en la mayoría de dominios conocidos.
- Las clases que se manejan dependen del dominio de aplicación.
- Esta tarea recibe también los nombres de: *categorización de textos*, *clasificación de documentos* e *identificación de temática*.

¿En qué casos se nos hace fácil la tarea de clasificación de textos?

Partidos contra un rival que suele vestir de blanco y que es muy poca cosa, en un estadio sin llenar y con muchísimos minutos donde no pasa absolutamente nada. Llegará el partido contra el siguiente equipo, donde sí habrá mucho en juego, pero hasta entonces, los choques de clasificación jugados en casa son todos iguales. La selección sale, juega poco, gana y se va.

¿En qué casos se nos hace fácil la tarea de clasificación de textos?


Eine für Freitag angesetzte Abstimmung wurde wegen mangelnder Erfolgsaussichten abgesagt. US-Präsident Donald Trump ist mit seinem ersten großen Gesetzesvorhaben gescheitert. Die Schuld gibt Trump den Demokraten.

Contenido

- 1 Introducción
- 2 Conceptos básicos**
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

Conceptos básicos (1)

- La **clasificación de textos** es una tarea que bien puede caer en el área de aprendizaje supervisado o en el área de aprendizaje no supervisado.
- Vamos a tratar primero la tarea de clasificación de textos como parte del aprendizaje supervisado.
 - Se tiene, normalmente, un conjunto de documentos etiquetados pertenecientes a una o varias clases.
 - Y un conjunto de *test* para evaluar el rendimiento del sistema.
- Un diagrama general del proceso es el siguiente:



Conceptos básicos (2)

- Puede formalizarse como la tarea de aproximar una función objetivo desconocida $f : D \times A \rightarrow \{-1, 1\}$ que corresponde a cómo los documentos serían clasificados por un experto.
- La función f es el clasificador, $A = \{a_1, a_2, \dots, a_{|A|}\}$ es el conjunto predefinido de $|A|$ temáticas (clases) y $D = \{d_1, d_2, \dots, d_n\}$ es la colección de documentos.
- Si $f(d_j, a_z) = 1$, el documento d_j es un ejemplo positivo de la temática a_z , mientras que si $f(d_j, a_z) = -1$, el documento es un ejemplo negativo de la temática a_z .

- De lo anterior puede decirse que la *clasificación de textos* es un ejercicio de clasificación binaria.
- Dependiendo del dominio de aplicación, cada documento puede pertenecer a una (*single-label task*) o a varias clases (*multi-label task*).
- En las tareas *multi-label* se suelen utilizar múltiples clasificadores binarios.

Contenido

- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos**
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

Representación de documentos

- Cada documento de la colección puede representarse por medio de un conjunto de palabras clave llamadas *index-terms*.
- De manera general, un *index-term* es un término que representa un concepto clave en un documento.
- Un conjunto cuidadosamente seleccionado de *index-terms* puede servir para resumir un documento, o al menos, para condensar sus conceptos principales.
- Para seleccionar los *index-terms* debemos pensar inicialmente en las palabras que llevan la mayor parte del contenido semántico de un documento, i.e. *sustantivos* y *verbos*.
- Sin embargo, es posible que ésta no sea la mejor estrategia (necesidad de un analizador sintáctico - *parser*).

Bag-of-words model - BOW


- Considerado como el punto de partida de la mayoría de modelos de representación de documentos.
- En el **modelo BOW** se ignora la estructura sintáctica de las oraciones y el orden de las palabras dentro del contexto propio de cada frase es irrelevante.
- Sin embargo, no pueden descuidarse las **entidades** ya que pierden mucho de su significado si son segmentadas a nivel de palabra.
 - Selección Colombia.
 - Poderoso de la montaña.
 - Furia matecaña.
 - ...
 - Constitución Política de Colombia.
 - Lenguaje Natural.

Bag-of-words model - BOW (2)



- Ya habíamos hablado del **vocabulario** de un corpus:
 - El conjunto de palabras que lo componían.
- Al conjunto de *index-terms* que componen un corpus lo llamaremos el **inventario de términos**.
- Cuando NO aplicamos procesos de reconocimiento de entidades, sino que tratamos todas las palabras por igual, el vocabulario se convierte en el **inventario de términos** de la tarea que estemos resolviendo.


Una vez obtenido el inventario...



Contenido

- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos**
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

Pre-procesamiento de documentos



Pre-procesamiento de documentos (2)

- Normalización de textos:

- Procesamiento estructural.

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE Trans SYSTEM "trans-13.dtd">
<Trans scribe="sergio-701" audio_filename="20040503_163243_170254_ES_INT">
<Topics>
<Topic id="to001" desc="EPPS 03. May 2004 - Formal opening of the first sitting
of the enlarged European Parliament"/>
</Topics>
<Speakers>
<Speaker id="spk2" name="interpreter#2<!--speaker#2" check="no" type="male"/>
<Speaker id="spk5" name="interpreter#1<!--speaker#2" check="no" type="female"/>
</Speakers>
<Episode>
<Section type="nontrans" startTime="0" endTime="108.94">
<Turn startTime="0" endTime="108.94">
<Sync time="0"/>
</Turn>
</Section>
<Section type="report" startTime="108.94" endTime="730.079" topic="to001">
<Turn speaker="spk6" startTime="108.94" endTime="201.311">
<Sync time="108.94"/>
en el exterior delante del edificio Louis Weiss para la ceremonia de apertura
<Sync time="114.408"/>
<Event desc="b" type="noise" extent="instantaneous"/>
de esta nueva Unión Europea
<Event desc="pause" type="noise" extent="instantaneous"/>
ampliada con los nuevos ehh miembros .
<Sync time="120.954"/>
...
</Turn>
</Section>
</Episode>
</Trans>
```

- Tokenización.
- Normalización (guiones, mayúsculas, acrónimos y siglas).

- **Stopwords removal:**

- Se eliminan palabras no-informativas (palabras con poca información léxica y/o que son muy frecuentes en el texto).
- Estas palabras no contribuyen en la identificación de las temáticas.
- Ejemplos de stopwords: artículos, preposiciones, pronombres y conjunciones.
- Reduce el inventario de términos (selección de características - reducción del espacio dimensional).
- En sistemas de *Information Retrieval* este paso puede no ser una buena idea.
 - **Ser o no ser.**
- Listas de *stopwords* pueden ser diseñadas para cada dominio.
- Distintas listas disponibles en Internet¹.

¹<https://github.com/eavgerinos/stop-words/tree/master/stop-words/stop-words-collection-2014.02.24/stop-words>

- **Lematización y stemming:**

- En tareas de clasificación de textos no está comprobada su eficiencia.

- **Index-terms selection:**

- Se parte del modelo BOW, pero se pueden explorar diferentes alternativas:
 - n-grams
 - *phrases* (colocaciones)
 - etiquetas POS
 - *skip-grams*

- **Term categorization (Thesaurus expansion):**

- Thesaurus: banco de sinónimos.
- Sirve para categorizar los *index-terms*.
- Y a la vez para expandir el inventario de términos.

Contenido

- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial**
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

Modelo de espacio vectorial (1)

- Existen diversos modelos para la representación de documentos, todos ellos enmarcados dentro de lo que se conoce como modelos clásicos.
 - Modelo booleano.
 - Modelo probabilístico.
 - **Modelo de espacio vectorial.**
- Modelo de espacio vectorial → empleado no sólo en IR (*Information Retrieval*), sino también en ML (*Machine Learning*).
- Este modelo ofrece una forma de representación natural de los documentos como vectores en un espacio m -dimensional compuesto por los *index-terms* que los conforman.

Modelo de espacio vectorial (2)

- Cada documento d_j puede representarse por el número de veces que aparece cada *index-term* en el documento. Esta forma de representación es lo que se conoce como la **matriz de términos en documentos (TDM - Term-Document Matrix)**.

$$TDM = \begin{matrix} & d_1 & d_2 & d_3 & \dots & d_n \\ \begin{bmatrix} c_{1,1} & c_{1,2} & c_{1,3} & & c_{1,n} \\ c_{2,1} & c_{2,2} & c_{2,3} & & c_{2,n} \\ c_{3,1} & c_{3,2} & c_{3,3} & & c_{3,n} \\ & & & \vdots & \\ c_{m,1} & c_{m,2} & c_{m,3} & & c_{m,n} \end{bmatrix} & \begin{matrix} t_1 \\ t_2 \\ t_3 \\ \vdots \\ t_m \end{matrix} \end{matrix}$$

Modelo de espacio vectorial (3)

$$TDM = \begin{bmatrix} & d_1 & d_2 & d_3 & \dots & d_n \\ c_{1,1} & c_{1,2} & c_{1,3} & & & c_{1,n} \\ c_{2,1} & c_{2,2} & c_{2,3} & & & c_{2,n} \\ c_{3,1} & c_{3,2} & c_{3,3} & & & c_{3,n} \\ & & & \vdots & & \\ c_{m,1} & c_{m,2} & c_{m,3} & & & c_{m,n} \end{bmatrix} \begin{matrix} t_1 \\ t_2 \\ t_3 \\ \vdots \\ t_m \end{matrix}$$

- donde $V = \{t_1, t_2, t_3, \dots, t_m\}$ es el **inventario de términos** (i.e. el conjunto de *index-terms* que se han seleccionado después de la etapa de pre-procesamiento)
- m es el número de *index-terms*
- t_i son los *index-terms* para $1 \leq i \leq m$
- $D = \{d_1, d_2, d_3, \dots, d_n\}$ la **colección** que contiene n documentos.
- Cada elemento $c_{i,j}$ representa el número de veces que el término t_i aparece en el documento d_j (a $c_{i,j}$ se le conoce como la *raw frequency*).

Modelo de espacio vectorial (4)

- Este modelo es lo que se conoce entonces como modelo de espacio vectorial (VSM - *vector space model*).
- En este modelo los términos son independientes entre sí.
- Cada documento puede ser presentado como un vector en un espacio m -dimensional

$$\vec{d}_j = [c_{1,j} \ c_{2,j} \ c_{3,j} \ \dots \ c_{m,j}]^T$$

- Y los documentos de evaluación (*queries*)


$$\vec{q} = [c_{1,q} \ c_{2,q} \ c_{3,q} \ \dots \ c_{m,q}]^T$$

- Esta representación permite entonces asociar los documentos a partir de la similitud que haya entre ellos; en este espacio de representación, la similitud es equivalente a hablar de la distancia que hay entre los vectores.

Modelo de espacio vectorial (5)

- Medida de similitud: distancia coseno

$$\text{sim}(\vec{d}_1, \vec{d}_2) = \cos \theta = \frac{\vec{d}_1 \bullet \vec{d}_2}{\|\vec{d}_1\| \|\vec{d}_2\|}$$



Modelo de espacio vectorial (6)

- Una ventaja de este modelo es que permite cuantificar la similitud en un rango continuo de valores entre -1 y 1.
- Esto hace posible no sólo clasificar documentos, sino también medir su “grado de pertenencia” a la clase.
- Hay que tener en cuenta que en este modelo de representación no todos los *index-terms* son igualmente útiles para describir el contenido de los documentos.
- Conviene preguntarse entonces, ¿cómo se podría resaltar la importancia de un término respecto a otros?

Contenido



- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos**
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis

Clasificación Supervisada vs. no supervisada

- La primera gran división que debemos hacer en los esquemas de clasificación depende de si los documentos se encuentran etiquetados o no.




Clasificación de Documentos



Esquemas de clasificación

- Sistemas basados en reglas (*rule-based systems*)
- Sistemas basados en aprendizaje de máquina (*machine learning - based systems*)

- Clasificadores basados en distancia
- Clasificador Naive Bayes
- SVM (*Support Vector Machines*)
- Aprendizaje profundo (*Deep Learning*)



- Sistemas híbridos (*hybrid systems*)

Contenido

- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM**
- 8 Latent Semantic Analysis

Esquemas de ponderado para VSM (1)

- En el VSM no todos los términos tienen la misma carga semántica. Esto se debe principalmente a:
 - Desde el punto de vista semántico, todos los términos tienen diferencias claras en su significado. No todos los términos son relevantes a la hora de describir conceptos inherentes a las distintas temáticas.
 - La distribución de los *index-terms* a lo largo de los documentos NO es uniforme.
 - La longitud de los documentos puede influir en el número de veces que estos aparezcan.
- Para contrarrestar estos problemas, se pueden aplicar pesos a los términos mediante esquemas de ponderado (*weighting-schemes*).
- El objetivo de un esquema de ponderado es asociar cada *index-term* con un peso que represente su relevancia no sólo respecto a los documentos en los que aparece sino también a los documentos en los cuales no aparece.

Esquemas de ponderado para VSM (2)

- Por ejemplo, un término que aparezca en todos los documentos tiene menor probabilidad de aportar información sobre algún documento.
- Caso contrario, un término que aparezca en pocos documentos.
- El objetivo de los esquemas de ponderado es el de maximizar dos propiedades de los términos y de los documentos: la *especificidad* y la *exhaustividad*.
 - **Especificidad:** Propiedad semántica de los términos.
Qué tan bien un término describe la temática de un documento.
 - **Exhaustividad:** Propiedad de los documentos.
Qué tan exhaustiva es la descripción de un documento en función del número de términos que posee. Entre más términos posea un documento, mas exhaustiva es su descripción.

Esquemas de ponderado para VSM (3)

- Los esquemas de ponderado se dividen en:
 - Ponderado local (*local weight*): Transforman cada uno de los $c_{i,j}$ elementos de manera independiente para cada documento.
Estos pesos dependen del número de veces que aparece cada término en cada documento.
 - Ponderado global (*global weight*): Transforman cada uno de los $c_{i,j}$ elementos de manera independiente para cada término.
Estos pesos dependen del número de veces que aparece cada término en la colección de documentos.

Esquemas de ponderado local (1)

- **Esquema binario:**

$$l_{i,j} = \begin{cases} 1 & \text{if } c_{i,j} > 0 \\ 0 & \text{if } c_{i,j} = 0 \end{cases}$$

- **Raw frequency:**

$$l_{i,j} = c_{i,j}$$

- **Log frequency:**

$$l_{i,j} = \begin{cases} 1 + \log(c_{i,j}) & \text{if } c_{i,j} > 0 \\ 0 & \text{otherwise} \end{cases}$$

Esquemas de ponderado local (2)

- **Term frequency:**

$$l_{i,j} = tf_{i,j} = \frac{c_{i,j}}{\theta_j}$$


donde θ es un factor de normalización definido como

$$\theta_j = \begin{cases} \sum_{k=1}^m c_{k,j} & \text{Document length normalization} \\ \sqrt{\sum_{k=1}^m c_{k,j}^2} & \text{Euclidean normalization} \end{cases}$$

- **Augmented and normalized frequency:**

$$l_{i,j} = \begin{cases} K + (1 - K) \left(\frac{c_{i,j}}{\max_i(c_{i,j})} \right) & \text{iff } t_i \in d_j \\ 0 & \text{otherwise} \end{cases}$$

Esquemas de ponderado local (3)



Esquemas de ponderado global (1)

- **Unitary weight:**

$$g_i = 1$$

- **Inverse document frequency:**

$$g_i = \log \left(\frac{n}{df_i} \right)$$

- **Probabilistic document frequency:**

$$g_i = \log \left(\frac{n - df_i}{df_i} \right)$$

Esquemas de ponderado global (2)

- **Global frequency - Inverse document frequency:**

$$g_i = \frac{gf_i}{df_i} \quad \text{where} \quad gf_i = \sum_{k=1}^n c_{i,k}$$

- **Term entropy:**

$$\epsilon_i = - \frac{1}{\log(n)} \sum_{j=1}^n p_{i,j} \log(p_{i,j}), \quad \text{where} \quad p_{i,j} = \frac{c_{i,j}}{gf_i}$$

Un valor de ϵ_i cercano a 1 indica un término distribuido a lo largo de muchos documentos en la colección. Un valor cercano a 0 indica que el término está presente sólo en unos pocos documentos.

$$g_i = 1 - \epsilon_i$$

$$g_i = 1 + \frac{1}{\log(n)} \sum_{j=1}^n p_{i,j} \log(p_{i,j})$$

Contenido

- 1 Introducción
- 2 Conceptos básicos
- 3 Representación de documentos
- 4 Pre-procesamiento de documentos
- 5 Modelo de espacio vectorial
- 6 Esquemas de clasificación de textos
- 7 Esquemas de ponderado para VSM
- 8 Latent Semantic Analysis**


- El modelo VSM (a pesar de ser muy empleado) tiene algunos inconvenientes:
 - El modelo VSM asume independencia mutua entre los términos de un documento.
 - Es incapaz de manejar dos problemas comunes del lenguaje:
 - **Sinonimia** (e.g. foto, fotografía)
 - **Polisemia** (e.g. carta, cura, radio)
 - No tiene en cuenta la **co-ocurrencia** de palabras.
 - El modelo VSM involucra una alta dimensionalidad en la representación (número de dimensiones igual a tamaño del inventario de términos).

- El **Análisis Semántico Latente** cubre las falencias del modelo VSM.
- **LSA** asume que hay una **estructura** latente en la co-ocurrencia de términos (esto mejora el manejo de la independencia de términos del modelo VSM).
- Para hacer visible esta estructura, **LSA** proyecta los documentos a un espacio de dimensiones “latentes”. En este espacio, los documentos que comparten términos, ocuparán una misma vecindad.
- El espacio **LSA** tiene un menor de dimensiones que el espacio VSM (la cual tiene tantas dimensiones como términos en la TDM). Esto la convierte también en una técnica de reducción de dimensionalidad.

LSA - *Latent Semantic Analysis* - Análisis Semántico Latente (2)

- Veamos primero un ejemplo gráfico (script*)

	d_1	d_2	d_3	d_4	d_5	d_6
<i>light</i>	1	0	1	0	1	0
<i>jupiter</i>	1	1	0	0	0	0
<i>mythology</i>	0	1	0	0	0	0
<i>picture</i>	1	0	0	1	0	0
<i>photograph</i>	0	0	0	1	1	1



LSA - *Latent Semantic Analysis* - Análisis Semántico Latente (3)

- Para aplicar LSA se debe partir de la versión “ponderada” de la TDM, es decir, la matriz TDM procesada por los esquemas de ponderado; vamos a llamarla matriz W .
- LSA emplea la **Descomposición en Valores Singulares - SVD**.
 - La SVD descompone la matriz W ($m \times n$) en el producto de tres matrices ($T_{m \times m}$, $S_{m \times n}$, $D_{n \times n}^T$).

The diagram shows the SVD decomposition of matrix W . On the left is a square representing matrix W with dimensions $m \times n$ indicated below it. To its right is an equals sign. Following the equals sign are three matrices multiplied together. The first matrix is a square representing T with dimensions $m \times m$ below it. This is followed by a multiplication sign 'x', then a square representing S with dimensions $m \times n$ below it. This is followed by another multiplication sign 'x', and finally a square representing D^T with dimensions $n \times n$ below it.

$$\begin{matrix} \boxed{} \\ m \times n \end{matrix} = \begin{matrix} \boxed{} \\ m \times m \end{matrix} \times \begin{matrix} \boxed{} \\ m \times n \end{matrix} \times \begin{matrix} \boxed{} \\ n \times n \end{matrix}$$

- Tenemos entonces

$$W_{m \times n} = T_{m \times m} \times S_{m \times n} \times D_{n \times n}^T$$

donde m es el número de *index-terms* y n el número de documentos en la colección.

- Los elementos de esta descomposición son:
 - T es una matriz cuadrada cuyas columnas son los eigenvectores de $W \cdot W^T$. Deben estar ortonormalizados de forma que cumplan $T \cdot T^T = I$. Esta matriz define el espacio vectorial de los términos en el espacio semántico latente.
 - D es una matriz cuadrada cuyas columnas son los eigenvectores de $W^T \cdot W$. Deben estar ortonormalizados de forma que cumplan $D^T \cdot D = I$. Esta matriz define el espacio vectorial de los documentos en el espacio semántico latente.

- S es una matriz rectangular cuya diagonal principal contiene los valores singulares de W . Estos valores deben estar ordenados de forma descendente, de manera que $\text{diag}(S) = [\lambda_1, \lambda_2, \dots, \lambda_r]$ donde $\lambda_1 > \lambda_2 > \dots > \lambda_r$. Los valores singulares λ_i indican el “peso” o la “contribución” a lo largo de la i -ésima dimensión del espacio semántico latente.

LSA - *Latent Semantic Analysis* - Análisis Semántico Latente (6)

- El punto clave del LSA es que una vez factorizada la matriz W (en T , S y D^T), muchos de los componentes linealmente independientes son muy pequeños y pueden ser ignorados (los valores singulares más pequeños λ_i de la diagonal principal de S).
- Esto lleva a un modelo aproximado que claramente puede contener un **menor número de dimensiones**.
- Por tanto, seleccionando los k valores singulares más grandes, y sus respectivas columnas y filas en las matrices T y D^T es posible obtener una **representación truncada** del **espacio semántico latente** usando menos dimensiones.

LSA - *Latent Semantic Analysis* - Análisis Semántico Latente (6)

- El punto clave del LSA es que una vez factorizada la matriz W (en T , S y D^T), muchos de los componentes linealmente independientes son muy pequeños y pueden ser ignorados (los valores singulares más pequeños λ_i de la diagonal principal de S).
- Esto lleva a un modelo aproximado que claramente puede contener un **menor número de dimensiones**.
- Por tanto, seleccionando los k valores singulares más grandes, y sus respectivas columnas y filas en las matrices T y D^T es posible obtener una **representación truncada** del **espacio semántico latente** usando menos dimensiones.

The diagram illustrates the LSA matrix factorization equation:

$$W_{m \times n} \approx \hat{T}_{m \times k} \times \hat{S}_{k \times k} \times \hat{D}^T_{k \times n}$$

The matrices are represented as follows:

- W : A white square representing the original matrix of size $m \times n$.
- $\hat{T}$: A black square representing the truncated term matrix of size $m \times k$.
- $\hat{S}$: A black square representing the truncated singular value matrix of size $k \times k$.
- $\hat{D}^T$: A black square representing the truncated document-term matrix of size $k \times n$.

- Esta representación truncada será igual entonces a

$$W_{m \times n} \approx \hat{T}_{m \times k} \cdot \hat{S}_{k \times k} \cdot \hat{D}_{k \times n}^T$$

- El valor de k determinará el número de dimensiones en el espacio semántico latente *truncado*.
- Si bien este valor puede ser encontrado experimentalmente, algunos autores sugieren que puede estar en el rango $[50 - 100]$ ², otros sugieren que puede ser alrededor de 300³, mientras que otros sugieren que puede ir de $[100 - 150]$ ⁴.

²[Deerwester et al., 1990]

³[Landauer and Dumais, 1997]

⁴[Manning and Schütze, 1999]

- ¿Cómo evaluar entonces un documento nuevo d_q ? (clasificar un documento)
 - Primero, tenemos que aplicar al documento los mismos esquemas de ponderado que hayamos empleado con el conjunto de entrenamiento $d_q \Rightarrow wd_q$
 - Luego, proyectamos el documento en el espacio semántico latente haciendo uso de las matrices de proyección obtenidas como resultado de la SVD.

$$\vec{d}_{lsa} = \vec{d}_q^T \cdot \hat{T} \cdot \hat{S}^{-1}$$



Echeverry-Correa, J.D. (2015).

Contributions to Speech Analytics based on Speech Recognition and Topic Identification
PhD. Thesis, Universidad Politécnica de Madrid, 2015



Manning, C. and Schütze, H. (2001).

Foundations of Statistical Natural Language Processing.
The MIT Press. 1st Edition. 2001